

Predição de Produtividade Agrícola e Classificação de Desempenho Produtivo em Municípios Brasileiros: Uma Abordagem Baseada em Aprendizado de Máquina sobre o Data Lakehouse Agroharvest-BRv2

*Projeto Final apresentado à disciplina CET0621 – Aprendizado de Máquina na Análise de Dados

Ciro Fraga de Souza
Faculdade de Tecnologia
UNICAMP
Limeira, Brasil
RA 2024211941

Felippe Dada Gaede
Faculdade de Tecnologia
UNICAMP
Limeira, Brasil
RA 2024212018

Jonnerson Lopes
Faculdade de Tecnologia
UNICAMP
Limeira, Brasil
RA 2024212042

Murilo Melo de Oliveira
Faculdade de Tecnologia
UNICAMP
Limeira, Brasil
RA 2024212085

Abstract—Este trabalho apresenta a aplicação de técnicas de aprendizado de máquina supervisionado para predição de produtividade agrícola e classificação de desempenho produtivo em municípios brasileiros. A partir dos dados consolidados no Data Lakehouse *Agroharvest-BRv2* (baseado em DuckDB), contendo informações municipais de produção (PAM/IBGE), zoneamento agrícola (ZARC/MAPA) e meteorologia histórica (Open-Meteo), construiu-se um dataset analítico com 7.549 registros focados nas culturas de soja e milho. Para a tarefa de regressão (predição de produtividade em kg/ha), testou-se modelos de MLP Regressor, Random Forest e XGBoost. Para a classificação multiclasse de faixas de desempenho produtivo (Baixo, Médio e Alto), avaliou-se classificadores Naive Bayes, k-NN, MLP e Bagging MLP. O algoritmo Random Forest obteve o melhor desempenho na regressão com $R^2 = 0,7574$, enquanto o k-NN com distância Manhattan obteve o melhor desempenho na classificação com acurácia de 70,40%. Os resultados evidenciam a eficácia de modelos preditivos integrando dados meteorológicos e agronômicos locais para apoiar tomadas de decisão.

Index Terms—Aprendizado de Máquina, Engenharia de Dados, Produtividade Agrícola, Desempenho Produtivo, Data Lakehouse.

I. INTRODUÇÃO

O agronegócio brasileiro é um dos principais motores econômicos do país, respondendo por aproximadamente 24% do Produto Interno Bruto (PIB) nacional, conforme dados oficiais estimativos do Centro de Estudos Avançados em Economia Aplicada (Cepea/Esalq-USP) [3]. No entanto, a atividade é altamente exposta a riscos bióticos e abióticos, como variações climáticas drásticas, amplitude térmica e escolha incorreta de cultivares em janelas de plantio inadequadas.

A modelagem de predição agrícola tradicional frequentemente depara-se com a barreira do silo de dados: dados de produção coletados pelo IBGE (Produção Agrícola Municipal

- PAM) [7], zoneamentos de plantio emitidos pelo MAPA (ZARC) [8] e dados de meteorologia histórica (como a API Open-Meteo) residem em plataformas e formatos heterogêneos.

A consolidação do Data Lakehouse *Agroharvest-BRv2* reduziu significativamente o esforço de integração de dados dessas bases públicas, disponibilizando-os em tabelas normalizadas com DuckDB e Apache Parquet. A partir dessa estrutura, este trabalho realiza a modelagem preditiva utilizando o processo de descoberta de conhecimento em bancos de dados (KDD). As tarefas foram divididas em duas vertentes complementares de aprendizado supervisionado: a estimação da produtividade municipal em kg/ha (regressão) e a classificação municipal da classe de desempenho produtivo associada à cultura e ao local (classificação multiclasse).

II. TRABALHOS RELACIONADOS

A literatura científica recente tem explorado intensamente o uso de técnicas de Inteligência Artificial para a otimização de safras e mitigação de perdas agrícolas. Chlingaryan et al. [1] revisaram exhaustivamente as abordagens baseadas em aprendizado de máquina para predição de rendimento e apontaram que dados históricos de precipitação e temperatura acumulada são os melhores preditores para o rendimento de culturas de larga escala.

Tradicionalmente, os dados climáticos eram coletados por estações físicas locais limitadas. Khaki e Wang [2] propuseram redes neurais profundas (DNN) para prever a produtividade de milho e soja integrando dados climáticos globais de satélites com genética de sementes, obtendo coeficientes de correlação superiores a 0.70. No entanto, o custo computacional e de

infraestrutura para manter tais modelos DNN em nuvem limita sua adoção prática por cooperativas locais.

Na vertente de arquitetura de dados, Armbrust et al. [4] propuseram o conceito de Data Lakehouse como um sistema unificado que estende os data lakes com transações ACID, versionamento de dados e otimizações de cache in-memory para alto desempenho em queries analíticas. No contexto agrícola, Wolfert et al. [5] analisaram as potencialidades e desafios do uso de Big Data no Smart Farming, apontando a necessidade de infraestruturas centralizadas e robustas para integrar múltiplos fluxos de informação. Em termos de modelagem preditiva, van Klompenburg et al. [6] realizaram um mapeamento sistemático de algoritmos para predição de safra e constataram que ensembles baseados em árvores de decisão como *Random Forest* [9] e variações de *Gradient Boosting* frequentemente superam Redes Neurais Artificiais quando os conjuntos de dados apresentam alta variabilidade regional e dimensionalidade moderada (< 30 atributos).

Este trabalho diferencia-se dos demais ao utilizar a estrutura local portátil de um Data Lakehouse integrado em DuckDB, eliminando custos operacionais de banco de dados e focando na modelagem híbrida (Classificação e Regressão) conforme proposto pela metodologia KDD.

III. METODOLOGIA

O desenvolvimento deste projeto seguiu o ciclo completo do framework KDD, detalhado nas etapas a seguir.

A. Construção do Dataset Analítico (Integração)

O Data Lakehouse foi consultado de forma unificada utilizando o DuckDB. A tabela de produção *fato_producao_pam* (dados reais de 2021) [7] foi filtrada para selecionar os registros das duas culturas dominantes do agronegócio brasileiro: soja e milho.

Para integrar a base climatológica diária (*fato_meteorologia*), que possui dados de 29 estações meteorológicas regionais distribuídas, utilizou-se a distância geográfica espacial. Através das coordenadas de latitude e longitude de todos os 5.570 municípios do Brasil (mapeadas a partir do arquivo *municipios_coords.csv*), calculou-se a distância de Haversine de cada município até a estação mais próxima:

$$d = 2r \arcsin \left(\sqrt{\sin^2 \frac{\Delta\phi}{2} + \cos \phi_1 \cos \phi_2 \sin^2 \frac{\Delta\lambda}{2}} \right) \quad (1)$$

onde ϕ representa a latitude, λ a longitude e r o raio terrestre ($r \approx 6371.0$ km).

A escolha do cálculo de distância geoespacial de Haversine em detrimento da distância Euclidiana simples justifica-se pela curvatura da Terra, a qual introduziria distorções de escala métrica significativas no cruzamento das coordenadas brasileiras dado que o território nacional se estende por mais de 4.000 km de distância linear. O pareamento por Haversine permitiu vincular de forma robusta e precisa cada município agrícola ao perfil climatológico mais realista de sua micror-região.

Dessa forma, a meteorologia histórica agregada em médias anuais (precipitação anualizada, temperaturas médias, mínimas e máximas locais) foi imputada de forma representativa para cada município produtor. Os dados de zoneamento *fato_risco_zarc* [8] foram agrupados por média de risco municipal por cultura. A base final consolidada resultou em 7.549 instâncias amostrais.

B. Pré-processamento e Prevenção de Vazamento de Dados (KDD)

Para assegurar o rigor metodológico da modelagem preditiva, todas as variáveis que poderiam causar vazamento de informação (*data leakage*) foram rigorosamente excluídas do conjunto de variáveis preditoras antes da modelagem. Especificamente, removeu-se os atributos *quantidade produzida* (*qtde_produzida_ton*), *área colhida* (*area_colhida_ha*) e *valor da produção* (*valor_producao_mil_reais*), além de IDs de controle do sistema e a coluna de umidade média anual (100% nula no banco). Desse modo, o modelo prevê a produtividade futura de forma estritamente cega, contando apenas com atributos climáticos e geoespaciais disponíveis antes do fechamento de safras.

A produtividade real do município em kg/ha foi computada como variável alvo de regressão. Para a classificação de desempenho produtivo, discretizou-se a produtividade em três faixas balanceadas baseadas nos percentis 33,3% e 66,6% calculados de forma independente por cultura. Isso foi feito para evitar viés de capacidade produtiva intrínseca de cada espécie (o milho possui uma média em kg/ha muito superior à soja). As classes de desempenho resultantes do mapeamento foram:

- **Baixo Desempenho:** Soja $\leq 3060,1$ kg/ha | Milho $\leq 1803,2$ kg/ha;
- **Médio Desempenho:** Soja entre 3060,1 e 3511 kg/ha | Milho entre 1803,2 e 4645,5 kg/ha;
- **Alto Desempenho:** Soja > 3511 kg/ha | Milho $> 4645,5$ kg/ha.

O dataset foi dividido na proporção de 80% para treino (6.039 amostras) e 20% para teste (1.510 amostras) de forma estratificada. O atributo de região geográfica do município e a cultura foram encodados via *One-Hot Encoding*. Para os modelos sensíveis a escala (k-NN, redes neurais MLP e Naive Bayes), utilizou-se o *StandardScaler* para centralizar e homogeneizar a variância dos dados.

C. Modelagem e Tuning de Hiperparâmetros

Para a tarefa de regressão, treinou-se três algoritmos: Multi-Layer Perceptron (MLP) Regressor, Random Forest Regressor e XGBoost Regressor. Para a tarefa de classificação multiclasse, treinou-se quatro algoritmos: Naive Bayes (GaussianNB), k-Nearest Neighbors (k-NN), Multi-Layer Perceptron (MLP) Classifier e um Ensemble Bagging com base de MLP. A seleção e fundamentação teórica desses algoritmos basearam-se no material didático e diretrizes metodológicas da disciplina de Aprendizado de Máquina [10].

Todos os modelos passaram por sintonia fina de hiperparâmetros usando a metodologia de busca exaustiva em grid (*GridSearchCV*) sob validação cruzada estratificada em 5 pastas (*5-Fold Cross-Validation*).

IV. RESULTADOS E DISCUSSÃO

A. Estimação de Produtividade (Regressão)

Os resultados obtidos pelos modelos de regressão antes e após o processo de sintonia de hiperparâmetros são sintetizados na Tabela I.

TABLE I
COMPARAÇÃO DE MODELOS DE REGRESSÃO (PRODUTIVIDADE)

Modelo	Estado	MAE (kg/ha)	RMSE (kg/ha)	R^2
MLP Regressor	Base	929,13	1342,42	0,5836
	Tuned	820,17	1233,76	0,6483
Random Forest	Base	669,41	1023,46	0,7580
	Tuned	668,96	1024,72	0,7574
XGBoost	Base	722,34	1092,21	0,7243
	Tuned	693,74	1050,66	0,7449

A Random Forest obteve o menor erro absoluto médio (MAE de 668,96 kg/ha) e o maior coeficiente de determinação ($R^2 = 0,7574$). Esse desempenho indica que os modelos baseados em ensembles de árvores de decisão conseguem mapear os limites de produtividade regional e climatológica sem requerer linearidade estrita das variáveis físicas.

Observa-se na Tabela I que o modelo Random Forest sintonizado (*Tuned*) apresentou uma redução marginal no erro absoluto médio (MAE caiu de 669,41 para 668,96 kg/ha), porém acompanhado por uma redução sutil no R^2 (0,7580 para 0,7574). Essa pequena oscilação é justificável numericamente: o *GridSearchCV* otimiza os hiperparâmetros com base no desempenho médio ponderado em 5 partições distintas de validação cruzada para maximizar a generalização e evitar o sobreajuste (*overfitting*). Esse compromisso de regularização pode levar a uma sutil perda aritmética na partição holdout de teste em favor de uma estabilidade muito maior do modelo em novos ambientes de produção.

A MLP Regressor apresentou ganho substancial após o tuning (R^2 subiu de 0,5836 para 0,6483), evidenciando a sensibilidade das redes neurais à estrutura de camadas e coeficiente de regularização L2 ($\alpha = 0.001$). O XGBoost apresentou excelente ganho de generalização, subindo seu R^2 de 0.7243 para 0.7449 sob o ajuste de taxa de aprendizado para 0.1. A importância relativa de cada feature para o modelo Random Forest é ilustrada na Fig. 1.

Observa-se que a localização geográfica (latitude e longitude) e a área plantada estimada (*area_plantada_ha*) do município foram as features mais decisivas, refletindo a concentração tecnológica da produção agrícola brasileira em regiões e polos específicos de alta produtividade (como o Centro-Oeste e o Oeste Baiano). A precipitação anual e a amplitude térmica local também exerceram papel decisivo




Fig. 1. Importância das variáveis obtida pelo melhor modelo de regressão (Random Forest).

como reguladores climáticos. A forte dependência das coordenadas geográficas evidencia um viés espacial na produtividade agrícola, onde fatores históricos de infraestrutura regional e topografia plana (como o cerrado plano de Mato Grosso) superam pequenas oscilações climáticas anuais locais. Contudo, cabe ressaltar uma limitação metodológica importante associada à alta importância das coordenadas geográficas: o risco de memorização espacial (*spatial overfitting*) em detrimento da generalização de padrões biofísicos. Sem uma validação cruzada espacial (como a separação por estados ou regiões fisiográficas no split de teste), não é possível descartar a ocorrência de memorização locacional no modelo baseado em Random Forest, limitando sua portabilidade para predição em regiões de fronteira agrícola recentemente abertas.

B. Classificação de Desempenho Produtivo

Os classificadores multiclasse de desempenho foram avaliados pelas métricas de acurácia, precisão macro, revocação (recall) macro e pontuação F1-Macro. Os resultados comparativos constam na Tabela II.

TABLE II
COMPARAÇÃO DE MODELOS DE CLASSIFICAÇÃO (DESEMPENHO)

Modelo	Estado	Acurácia	Precisão	Recall	F1-Macro
Naive Bayes	Base/Tuned	0,5099	0,5022	0,5098	0,4451
k-NN	Base	0,6861	0,6824	0,6861	0,6835
	Tuned	0,7040	0,7034	0,7040	0,7036
MLP Classifier	Base	0,6755	0,6697	0,6755	0,6709
	Tuned	0,6781	0,6738	0,6781	0,6751
Bagging MLP	Base	0,6821	0,6767	0,6821	0,6779
	Tuned	0,6755	0,6705	0,6755	0,6719

O classificador k-NN ajustado com distância Manhattan e peso ponderado de distância ($k = 7$) superou os demais com acurácia de 70,40% e F1-Macro de 70,36%. Esse comportamento indica que municípios vizinhos geograficamente e com perfis climáticos similares possuem fortes agrupamentos no espaço Euclidiano de desempenho, validando o conceito agrônomo de contiguidade de produtividade regional.

O Naive Bayes obteve o menor desempenho (50,99% de acurácia), o que pode ser explicado pela forte correlação entre os atributos climáticos (como temperaturas e precipitações locais), violando a hipótese de independência condicional assumida pelo classificador. O Ensemble Bagging com base de MLP forneceu previsões bastante estáveis (67,55%), mostrando a vantagem de comitês na generalização e redução de variância estocástica de redes neurais individuais. As figuras das matrizes de confusão do k-NN e Bagging MLP são apresentadas na Fig. 2.




Fig. 2. Matriz de Confusão do melhor modelo classificador (k-NN).

A matriz de confusão demonstra que o modelo possui alta precisão para identificar a classe “Baixo” desempenho produtivo, com baixo nível de confusão com o outro extremo (classe “Alto”). O maior ruído de predição ocorre na classe “Médio”, que possui fronteiras de decisão mais tênues com as classes extremas.

Na análise da dinâmica de convergência da rede neural MLP, constatou-se que a regularização L2 atuou ativamente impedindo o sobreajuste nos pesos de atributos categóricos encodados, que poderiam polarizar a rede caso não houvesse decaimento de peso penalizado. A rede convergiu uniformemente com a taxa de aprendizado sintonizada em 0.001, evitando as instabilidades de mínimos locais que ocorreram no modelo base com taxa padrão mais elevada.

V. CONCLUSÃO

Este trabalho aplicou com sucesso a metodologia KDD sobre a base unificada de dados do lakehouse *Agroharvest-BRv2*. O dataset construído demonstrou grande consistência para treinar modelos preditivos de forma robusta e livre de vazamento de informações. O estimador Random Forest destacou-se na regressão de produtividade agrícola com coeficiente R^2 de 0,7574, mapeando de forma eficiente a influência da geografia e do clima local. Por sua vez, o classificador k-NN demonstrou ser altamente eficaz para segmentação de faixas de desempenho produtivo municipal (70,40% de acurácia).

Trabalhos futuros incluem expandir a granularidade temporal do dataset integrando séries plurianuais históricas do PAM e do ZARC para além do ano de 2021, bem como incorporar features de sensoriamento remoto de satélites para captura da biomassa foliar em tempo real.

REFERENCES

- [1] A. Chlingaryan, S. Sukkarieh, and B. Whelan, “Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture: A review,” *Computers and Electronics in Agriculture*, vol. 151, pp. 61–69, 2018.
- [2] S. Khaki and L. Wang, “Crop yield prediction using deep neural networks,” *Frontiers in Plant Science*, vol. 10, article 621, 2019.
- [3] CEPEA/ESALQ-USP, “PIB do Agronegócio Brasileiro: Relatório Anual 2023,” Centro de Estudos Avançados em Economia Aplicada (Cepea), Piracicaba, SP, 2024. [Online]. Disponível em: <https://www.cepea.esalq.usp.br/br/pib-do-agronegocio-brasileiro.aspx>. Acesso em: 4 de jun. de 2026.
- [4] M. Armbrust et al., “Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics,” in *Proceedings of the 11th Conference on Innovative Data Systems Research (CIDR)*, 2021.
- [5] S. Wolfert, L. Ge, J. Verdouw, and M. J. Bogaardt, “Big data in smart farming—A review,” *Agricultural Systems*, vol. 153, pp. 69–80, 2017.
- [6] T. van Klompenburg, A. Kassahun, and C. Catal, “Crop yield prediction using machine learning: A systematic literature review,” *Computers and Electronics in Agriculture*, vol. 177, p. 105709, 2020.
- [7] IBGE. Produção Agrícola Municipal (PAM). Disponível em: <https://sidra.ibge.gov.br/>.
- [8] MAPA. Zoneamento Agrícola de Risco Climático (ZARC). Disponível em: <https://indicadores.agricultura.gov.br/zarc/>.
- [9] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001.
- [10] G. P. Coelho, *Material da disciplina CET0621 – Aprendizado de Máquina na Análise de Dados*. UNICAMP/FT, 2026.

APÊNDICE: AVALIAÇÃO POR PARES E CONTRIBUIÇÕES DOS AUTORES

De acordo com as diretrizes do projeto final estabelecidas para a disciplina CET0621, a Tabela III detalha as contribuições de cada integrante do grupo para o desenvolvimento deste projeto, acompanhadas de suas respectivas notas de participação.

TABLE III
NOTAS DE PARTICIPAÇÃO E CONTRIBUIÇÕES DETALHADAS POR MEMBRO

Integrante	RA	Nota de Part. (p_i)	Descrição das Contribuições no Projeto
Ciro Fraga de Souza	2024211941	10,0	Engenharia de dados e infraestrutura. Implementou as consultas no DuckDB do Data Lakehouse, fez a unificação espacial usando a distância de Haversine para as coordenadas meteorológicas e construiu o script de ETL do dataset analítico.
Felippe Dada Gaede	2024212018	10,0	Pré-processamento e análise exploratória de dados. Responsável pelo tratamento de nulos, imputação, codificação categórica One-Hot Encoding e divisão estratificada treino/teste. Escreveu o pipeline de scaling.
Jonnerson Lopes	2024212042	10,0	Treinamento e sintonia dos modelos. Implementou os scripts de treinamento de Regressão e Classificação, orquestrou as buscas Grid-SearchCV para sintonizar os hiperparâmetros dos modelos (MLP, RF, XGBoost, k-NN) no Docker.
Murilo Melo de Oliveira	2024212085	10,0	Avaliação de desempenho e elaboração do relatório final. Confeccionou as visualizações das matrizes de confusão, gráfico de real vs predito e importância de variáveis. Estruturou e redigiu o documento no formato IEEE.